

The background image shows the interior of a grand library, likely the Bibliothèque de la Ville de Paris. It features a high, vaulted ceiling with intricate metalwork and large skylights. The walls are lined with bookshelves, and the floor is covered with wooden tables and chairs. Several large, ornate lamps with green glass shades are visible. The overall atmosphere is one of a historic and well-maintained library.

Analyse de vente de librairie LAPAGE


Etude de vente et de suivi du marché afin d'aider l'équipe Marketing à adapter les stratégies en ligne

TABLE DES MATIÈRES

- Objectifs
- Préparation des données
- Chiffres clés
- Analyse de tendance
- Analyse de produits
- Analyse des profils clients
- Tests statistiques
- Conclusion
- Remerciement



Processus de nettoyage



0
1

Données de transactions

Adapter les types de données : "date"

Corriger **200 lignes non conformes**, ne respectant pas les formats :
"id_prod", "date", "session_id" et "client_id"

Données de clients

Il existe 2 clients non conformes (ct_0, ct_1)

Développer une nouvelle variable "Age" et vérifier sa validité

Jointure avec les données "transaction" cohérent



0
2



0
3

Données de produits

Il existe 1 produit non conforme au format "id_prod"

Ajouter dans les données un produit "0_2245", présent uniquement dans "transaction" (déduire son prix moyen par catégorie)



Chiffres clés

Transaction : **679 332** lignes x 4 colonnes
Client : **8 623** lignes x 3 colonnes (dont **8 600** actifs)
Produit : **3 287** lignes x 3 colonnes (dont **3 266** produits vendus)

Chiffre d'affaires

11,9 M

total pendant 03/2021
- 03/2023

Nombre de vente par jour

471

moyen pendant
03/2021 - 03/2023

Nombre de clients par jour

425


moyen pendant
03/2021 - 03/2023

Chiffre d'affaires moyen


16,3 K

moyen mobile sur 30j
pendant 03/2021 - 03/2023

Stabilité de l'évolution CA




- **Baisse brutale du CA** en octobre 2021
=> baisse des ventes des produits des catégories "0" et "1"
- **Hausse de CA** en février 2022
=> augmentation des ventes des catégories "0" et "2"
- **Evolution CA moyen stable** durant 2022 et début 2023, avec une légère hausse par rapport à 2021




Top 5 et Flop 5 des produits


- CA des **top 5** : concerne les produits de catégorie “2” :
 - CA le plus élevé : > 80 K €
 - Prix moyen de la catégorie “2” : **76 €**
- CA des **flop 5** : concerne les produits de catégorie “0”
 - CA le plus faible : 1 €
 - Prix moyen de la catégorie “0” : **10 €**



Top 5 et Flop 5 des produits



- CA des **top 5** : concerne les produits de catégorie "2" :
 - CA le plus élevé : > 80 K €
 - Prix moyen de la catégorie "2" : **76 €**
- CA des **flop 5** : concerne les produits de catégorie "0" :
 - CA le plus faible : 1 €
 - Prix moyen de la catégorie "0" : **10 €**






Validation de l'effet de Pareto sur les produits

- Indice de Gini : **74,3%** proche de 100%


80% du chiffre d'affaire est réalisé par 20% des produits





Caractéristiques similaires selon le genre


Homme



48 %

Client hommes


Femme



52 %

Client femmes



- Répartition équilibrée des clients selon le genre
- Panier moyen : **35 €**





Panier moyen est élevé pour les moins de 30 ans


- Répartition des clients :
> 1/3 ont 30-50 ans et 1/3 ont 50-70 ans
- Taille du panier moyen diminue avec l'âge
Panier moyen des jeunes : **70€**







Niveau de consommation faiblement inégalitaire

- 4 clients à caractère commercial
- Indice de Gini : 74,3% proche de 1
80% du chiffre d'affaires est réalisé par 50% des produits



Niveau de consommation faiblement inégalitaire

- 4 clients à caractère commercial
- Indice de Gini : 74,3% proche de 1
80% du chiffre d'affaires est réalisé par 50% des produits



Tests statistiques

- 01 | Test de Chi2 entre le genre et la catégorie de livres achetés
 - 02 | Test de Spearman entre l'âge des clients et le montant des achats
 - 03 | Test de Spearman entre l'âge des clients et le nombre d'achats
 - 04 | Test de Spearman entre l'âge des clients et le panier moyen
 - 05 | Test de KS entre l'âge des clients et la catégorie de livres achetés
-

Test de corrélation

01 - Test Chi-2


Etude entre le genre des clients et les catégories de produits

Choix de test (Fisher VS Chi-2) :

- Chi-2 est adapté au table de contingence 2x3 et d'échantillon de grande taille
- H0 : Variable A est indépendante à la variable B

Résultat :

- p-value : **1e-04** < 5%
- => On rejette H0, les 2 variables sont dépendantes



Distributions non gaussiennes

02 - Kolmogorov-Smirnov


Etude du chiffre d'affaires par client (+8 000 clients)

Choix de test (Shapiro VS KS):

- Test de KS adapté pour des données de grande taille (>2 000 clients)
- H0 : Données suivent la distribution normale

Résultat :

- p-valeur : **2e-76** < 5% (probabilité d'erreur en rejetant H0)
- => Chiffre d'affaires ne suit pas la distribution gaussienne



Distributions non gaussiennes

02 - Kolmogorov-Smirnov


Etude du nombre de transactions par client

Choix de test (Shapiro VS KS) :

- **Test de KS adapté pour des données de grande taille**
H0 : Données suivent la distribution normale

Résultat :

- p-value : **1e-169** < 5% (probabilité d'erreur en rejetant H0)
=> **Nombre de ventes par client ne suit pas la distribution gaussienne**



Distributions non gaussiennes

02 - Kolmogorov-Smirnov


Etude de la taille du panier moyen par client

Choix de test (Shapiro VS KS) :

- **Test de KS adapté pour des données de grande taille**
H0 : Données suivent la distribution normale

Résultat :

- p-value : **0** < 5% (probabilité d'erreur en rejetant H0)
=> Taille du panier moyen par client ne suit pas la distribution gaussienne



Distributions non gaussiennes

02 - Kolmogorov-Smirnov


Etude de l'âge des clients

Choix de test (Shapiro VS KS) :

- **Test de KS adapté pour des données de grande taille**
H0 : Données suivent la distribution normale

Résultat :

- p-value : **8e-31** < 5% (probabilité d'erreur en rejetant H0)
=> Age des clients ne suit pas la distribution gaussienne



CA diminue avec l'âge

03 - Test Spearman


Etude entre l'âge des clients et leur consommation

Choix de test (Pearson VS Spearman) :

- Données ne suivent pas la loi normale : test non paramétrique
H0 : Il n'y a pas de corrélation linéaire entre les 2 variables quantitatives

Résultat :

- p-value < 5% (probabilité d'erreur en rejetant H0 est très faible)
=> Il y a bien une corrélation linéaire entre 2 variables (coef. = **-0.18**)



Achats augmente avec l'âge

04 - Test Spearman


Etude entre l'âge des clients et le nombre de transactions

Choix de test (Pearson VS Spearman) :

- Données ne suivent pas la loi normale : test non paramétrique
H0 : Il n'y a pas de corrélation linéaire entre les 2 variables quantitatives

Résultat :

- p-value < 5% (probabilité d'erreur en rejetant H0 est très faible)
=> Il y a bien une corrélation linéaire entre 2 variables (coef. = 0.22)



Taille du panier diminue avec l'âge

05 - Test Spearman


Etude entre l'âge des clients et la taille de leur panier moyen

Choix de test (Pearson VS Spearman) :

- **Données ne suivent pas la loi normale : test non paramétrique**
H0 : Il n'y a pas de corrélation linéaire entre les 2 variables quantitatives

Résultat :

- p-value < 5% (probabilité d'erreur en rejetant H0 est très faible)
=> Il y a bien une corrélation linéaire entre 2 variables (coef. = -0.70)



Jeunes préfèrent la catégorie "2"

06 - Test Kruskal-Wallis


Etude entre les catégories de produits et l'âge des clients

Choix de test (ANOVA VS KW) :

- **Test KW** : adapté pour >2 groupes et l'âge ne suivent pas la loi normale
H0 : Pas de médiane significativement différente entre les groupes

Résultat :

- p-value : **0** < 5% (on rejette H0)
=> Il existe **au moins** une catégorie de produit qui possède une médiane différente des autres





Conclusion

Stratégie :
Attirer les jeunes clients

Produits

- “1” et “0” sont les populaires
- “2” apporte le plus de CA

Clients

- Clients âgés : achats fréquents
- Jeunes : achats plus chers

Préférence

- les plus jeunes : “2”
- > 40 ans : “1” et “0”



Merci pour votre attention !

Rongrong CAI

OpenClassroom
21/08/2025